

Teoría de Información Carrera: Licenciatura en Ciencias de la Computación
Año: 2026

ÁREA TEMÁTICA N° 1 PRÁCTICO 1: TEORÍA DE LA INFORMACIÓN
CANTIDAD DE INFORMACIÓN - ENTROPÍA

1. Análisis de Capacidad e Información en Imágenes Digitales

a) Suponga una imagen de alta definición (HD) dividida en una matriz de 1920 por 1080 píxeles. Indique la cantidad máxima teórica de información (en bits y en Megabytes) que proporciona este cuadro si está codificada en 24 bits por píxel.

b) Luego, considere una imagen en resolución 4K (3840 x 2160 píxeles). ¿Cuánta información máxima se genera si se codifica en formato HDR (High Dynamic Range) utilizando 10 bits por cada canal de color (Rojo, Verde y Azul)?

c) Análisis teórico: La cantidad de información calculada en los incisos anteriores, ¿representa la información "real" (Entropía) de una fotografía o únicamente su capacidad máxima de almacenamiento? Justifique su respuesta explicando el concepto de redundancia espacial.

a) Imagen HD (1920 × 1080, 24 bits por píxel)

- Total de píxeles: $1920 \times 1080 = 2.073.600$ píxeles.
- Información teórica máxima (bits): $2.073.600 \text{ píxeles} \times 24 \text{ bits/píxel} = 49.766.400 \text{ bits}$.
- Información teórica máxima (MB):
 - En sistema decimal ($1 \text{ MB} = 10^6 \text{ bytes} = 8 \times 10^6 \text{ bits}$):
$$\frac{49.766.400}{8 \times 10^6} = 6,2208 \text{ MB}$$
 - En sistema binario ($1 \text{ MiB} = 2^{20} \text{ bytes} = 8.388.608 \text{ bits}$):
$$\frac{49.766.400}{8.388.608} \approx 5,9326 \text{ MiB}$$

b) Imagen 4K HDR (3840 × 2160, 10 bits por canal RGB)

- Total de píxeles: $3840 \times 2160 = 8.294.400$ píxeles.
- Profundidad de color por píxel: $10 \text{ bits/canal} \times 3 \text{ canales}(R, G, B) = 30 \text{ bits/píxel}$.
- Información teórica máxima (bits): $8.294.400 \text{ píxeles} \times 30 \text{ bits/píxel} = 248.832.000 \text{ bits}$.
- Información teórica máxima (MB):
 - En sistema decimal:
$$\frac{248.832.000}{8 \times 10^6} = 31,104 \text{ MB}$$
 - En sistema binario:
$$\frac{248.832.000}{8.388.608} \approx 29,6631 \text{ MiB}$$

c) Análisis Teórico: Capacidad Máxima vs. Entropía Real

La cantidad de información calculada representa únicamente la capacidad máxima de almacenamiento de la matriz de píxeles (el espacio en bruto necesario si cada píxel fuera completamente independiente y tomará sus valores de forma equiprobable). No representa la entropía real de una fotografía.

- Redundancia Espacial: En cualquier fotografía real existe una alta correlación entre píxeles contiguos. Los elementos de la escena (cielo, paredes, rostros, texturas) provocan que un píxel tienda a tener un valor de color y luminancia muy similar al de sus vecinos inmediatos.
- Impacto en la Entropía: Al no ser los eventos (píxeles) independientes ni equiprobables en la práctica, la incertidumbre o "sorpresa" real al recibir cada píxel es reducida. Matemáticamente, la entropía real $H(X)$ de la imagen es muy inferior a la entropía máxima $H_{\max}$. La diferencia entre ambas es la redundancia ($R = H_{\max} - H$), la cual permite que algoritmos de compresión (como PNG para compresión sin pérdida o JPEG/WebP para compresión con pérdida) reduzcan drásticamente el tamaño del archivo final sin alterar sensiblemente el contenido visual.

2. Cantidad de Información en Modelos de Predicción de Texto Un sistema de autocompletado en un dispositivo móvil debe predecir la siguiente palabra que escribirá un usuario.

a) Si el vocabulario total del diccionario del sistema es de 15.000 palabras y, al iniciar una frase, el sistema asume a priori que cualquier palabra es equiprobable, ¿cuánta información (en bits) se genera al elegir una palabra exacta?

b) Suponga que, analizando el contexto de las palabras anteriores, un modelo de Inteligencia Artificial determina que solo hay 5 palabras lógicas posibles para continuar la frase, siendo estas 5 opciones equiprobables. ¿Cuánta información se genera ahora al confirmar cuál de esas 5 es la palabra correcta?

c) ¿Qué cantidad de información (en bits) aportó el contexto procesado por la Inteligencia Artificial al sistema? Explique qué significa este valor en términos de incertidumbre.

a) Información al elegir una palabra sin contexto ($N = 15.000$)

Al ser equiprobables, la probabilidad de seleccionar cualquier palabra es $P_i = \frac{1}{15.000}$.

$$I_a = \log_2 (15.000) \approx 13,8727 \text{ bits}$$

b) Información al confirmar la palabra con contexto ($N = 5$)

La probabilidad de cada una de las 5 opciones equiprobables es $P_i = \frac{1}{5}$.

$$I_b = \log_2 (5) \approx 2,3219 \text{ bits}$$

c) Información aportada por la Inteligencia Artificial y significado

- Información aportada por el contexto: Es la diferencia entre la incertidumbre inicial (sin contexto) y la incertidumbre remanente (con contexto):
 - $\Delta I = I_a - I_b = \log_2 (15.000) - \log_2 (5) = \log_2 \left(\frac{15.000}{5} \right) = \log_2 (3000) \approx 11,5507 \text{ bits}$
- Significado en términos de incertidumbre: Este valor (11,5507 bits) representa la reducción de la incertidumbre que logró el modelo de IA antes de que el usuario seleccione la palabra. El contexto "hizo el trabajo pesado" eliminando la enorme

mayoría de las alternativas del vocabulario (reduciendo el rango de posibilidad a una fracción de 1/3000). Por ende, al usuario únicamente le resta aportar los 2,3219 *bits* de incertidumbre finales para definir la palabra exacta.

3. Propiedades Matemáticas de la Información

a) Demostrar las siguientes igualdades correspondientes a la propiedad de cambio de base de los logaritmos:

$$\log_a x = \frac{\log_b x}{\log_b a} = \log_a b \cdot \log_b x$$

b) Justificación Teórica: Indique en qué situaciones prácticas de la Teoría de la Información resulta indispensable utilizar esta propiedad de cambio de base (Pista: Relacione este concepto con las unidades de medida de la información).

a) Demostración matemática

Primera igualdad: $\log_a x = \frac{\log_b x}{\log_b a}$

1. Definimos $y = \log_a x$. Por la definición de logaritmo, esto equivale a:

$$a^y = x$$

2. Aplicamos logaritmo en base b a ambos lados de la igualdad:

$$\log_b (a^y) = \log_b x$$

3. Aplicamos la propiedad del logaritmo de una potencia ($\log_b (u^k) = k \cdot \log_b u$):

$$y \cdot \log_b a = \log_b x$$

4. Despejamos y :

$$y = \frac{\log_b x}{\log_b a}$$

5. Sustituyendo $y = \log_a x$, obtenemos la primera igualdad:

$$\log_a x = \frac{\log_b x}{\log_b a}$$

Segunda igualdad: $\frac{\log_b x}{\log_b a} = \log_a b \cdot \log_b x$

1. Usando el resultado recién demostrado, si tomamos el caso particular donde $x = b$:

$$\log_a b = \frac{\log_b b}{\log_b a} = \frac{1}{\log_b a} \implies \frac{1}{\log_b a} = \log_a b$$

2. Reemplazando $\frac{1}{\log_b a}$ por $\log_a b$ en la fracción original:

$$\frac{\log_b x}{\log_b a} = \left(\frac{1}{\log_b a} \right) \cdot \log_b x = \log_a b \cdot \log_b x$$

Con esto quedan demostradas ambas expresiones.

b) Justificación Teórica y Unidades de Medida

La propiedad de cambio de base es indispensable en Teoría de la Información por dos razones principales:

- Conversión entre Unidades de Medida: La base del logaritmo determina la unidad en la que se mide la información o la entropía. Cambiar la base equivale a multiplicar la cantidad de información por una constante de conversión ($\log_a b$)
 - Base 2 (*bits* o *shannons*): Es la unidad estándar en ciencias de la computación y comunicaciones digitales.
 - Base e (*nats*): Se utiliza frecuentemente en demostraciones teóricas, análisis de canales continuos y cálculo diferencial (como vimos en las demostraciones analíticas del óptimo de entropía).
 - Base 10 (*dits*, *hartleys* o *bans*): Usada históricamente en ciertos cálculos decimales.
- Por ejemplo, para convertir un valor calculado en nats (H_{nats}) a bits (H_{bits}):
 - $H_{bits} = \frac{H_{nats}}{\ln 2} = \log_2(e) \cdot H_{nats} \approx 1,4427 \cdot H_{nats}$
- Cálculo Numérico y Algorítmico: Las bibliotecas estándar de lenguajes de programación y calculadoras suelen implementar únicamente logaritmos en base e ($\log()$ / $\ln()$) o en base 10 ($\log_{10}()$). Para computar entropías o cantidades de información en bits en código, se recurre computacionalmente a $\log_2 x = \frac{\ln x}{\ln 2}$.

4. Entropía en Sistemas de Reconocimiento Automático En el desarrollo de un modelo de Machine Learning para la traducción automatizada, el sistema debe clasificar 5 configuraciones básicas (). Tras analizar un corpus de datos, se determina que la configuración es la más frecuente, con una probabilidad , mientras que las otras cuatro configuraciones son equiprobables con cada una.

a) Calcula la cantidad de información individual que aporta la detección de cada configuración.

b) Calcula la entropía total de esta fuente de información.

c) Si el sistema se calibra para que todas las configuraciones tengan exactamente la misma probabilidad de aparición, ¿la entropía aumentaría o disminuiría? Justifica tu respuesta.

a) $I_{c1} = \log_2(3) = 1.585 \text{ bits}$

$$I_{c2} = I_{c3} = I_{c4} = I_{c5} = \log_2(6) = 2.585 \text{ bits}$$

b) $H = \frac{1}{3} \log_2(3) + 4(\frac{1}{6} \log_2(6)) \approx 2.2516 \text{ bits de información promedio}$

c) La entropía aumenta con la equiprobabilidad.

5. Entropía Máxima vs. Entropía Real en un Pipeline de Datos Un pipeline de backend clasifica las peticiones entrantes de los usuarios en 8 categorías o intenciones distintas.

a) Demuestra matemáticamente que si el balanceador de carga distribuye las peticiones de forma tal que las 8 categorías tienen exactamente la misma probabilidad de ocurrir, el sistema alcanza su máxima incertidumbre (entropía máxima). ¿Cuál es ese valor en bits?

b) Al pasar el sistema a producción, se observa que el tráfico real está fuertemente sesgado, respondiendo a la siguiente distribución de probabilidades: $p_1=0.5$, $p_2=0.2$, $p_3=0.1$, $p_4=0.08$, $p_5=0.06$, $p_6=0.04$, $p_7=0.015$, $p_8=0.005$. Calcula la entropía real del sistema en producción.

c) Compara ambos resultados (inciso a vs inciso b). ¿Qué nos dice esta diferencia (caída de entropía) sobre la predictibilidad del comportamiento de los usuarios?

a) $H_{max} = \log_2(8) = 3 \text{ bits}$

b)
$$H = 0.5 \log_2(1/0.5) + 0.2 \log_2(1/0.2) + 0.1 \log_2(1/0.1) + 0.08 \log_2(1/0.08) \\ + 0.06 \log_2(1/0.06) + 0.04 \log_2(1/0.04) + 0.015 \log_2(1/0.015) \\ + 0.005 \log_2(1/0.005) \\ = 2.3451 \text{ bits de información promedio}$$

c) La entropía aumenta con la equiprobabilidad.

6. Entropía Teórica vs. Redundancia en el Lenguaje Considere un alfabeto teórico de 27 letras.

a) Calcule la cantidad de información (Entropía Máxima) que genera la elección de 1 sola letra, una secuencia de 2 letras y una secuencia de 3 letras, asumiendo a priori que todas las letras son equiprobables y la elección de cada letra es completamente independiente de las demás.

b) Si pasamos de este "alfabeto teórico" al uso real del idioma español, el principio de equiprobabilidad desaparece. Explique por qué sucede esto y cómo afecta al valor de la entropía real de un carácter.

c) En el idioma español tampoco se cumple el principio de independencia (las letras están condicionadas por las anteriores). Dé un ejemplo de dependencia fuerte entre dos letras en español y explique conceptualmente qué sucede con la cantidad de información generada al leer la segunda letra.

a) Para un alfabeto teórico de $q = 27$ letras, asumiendo equiprobabilidad $p_i = 1/27$ e independencia estadística entre los símbolos elegidos, la incertidumbre y la cantidad de información por elección se calculan utilizando la fórmula de entropía máxima $H_{\max} = \log_2(q)$:

1 sola letra: La cantidad de información generada por la elección de un símbolo equiprobable es: $H_{\max} = \log_2(27) \approx 4,755 \text{ bits}$

Secuencia de 2 letras: Al ser selecciones estadísticamente independientes, la información es aditiva $I(E_1 \cap E_2) = I(E_1) + I(E_2)$, lo cual equivale a considerar el espacio de $27^2 = 729$ combinaciones equiprobables: $H(S^2) = \log_2(27^2) = 2 \cdot \log_2(27) \approx 9,510 \text{ bits}$

Secuencia de 3 letras: De manera análoga, para una cadena de 3 caracteres independientes con $27^3 = 19.683$ combinaciones equiprobables, se obtiene: $H(S^3) = \log_2(27^3) = 3 \cdot \log_2(27) \approx 14,265 \text{ bits}$

- b) En el uso real del idioma español, el principio de equiprobabilidad desaparece porque las letras no aparecen con la misma frecuencia relativa; vocales como la "a" o la "e" y consonantes como la "s" o la "r" son muy frecuentes, mientras que caracteres como la "k", "w" o "x" tienen probabilidades muy bajas de aparición.

Efecto en la entropía real:

La entropía de una fuente alcanza su límite máximo $H_{\max} = \log_2 \square$ únicamente cuando todos sus símbolos son equiprobables. Cualquier desbalance en la distribución de probabilidades reduce la incertidumbre media sobre qué símbolo aparecerá a continuación. Como consecuencia, la entropía real $H(S)$ de un carácter disminuye considerablemente en comparación con el valor teórico (cayendo en el castellano real a un rango de entre 1 y 1,5 bits/símbolo. Esta diferencia entre el rendimiento máximo y el real genera redundancia en el lenguaje tu expresión ($\square = 1 - H/S_{\max}$), , la cual en español alcanza aproximadamente un 68%.

- c) Un ejemplo claro de dependencia estadística fuerte en el idioma español es el par de letras "q" y "u" ($P(u|q) \approx 1$).

Si se lee la letra "q", la probabilidad condicional de que el carácter inmediatamente posterior sea una "u" es prácticamente igual a la certeza absoluta $I(u|q) = \log_2 (1/P(u|q))$.

Qué sucede conceptualmente con la información de la segunda letra?

La cantidad de información condicional que aporta la segunda letra al ser leída se define como $I(u|q) = \log_2 (1/P(u|q))$. Dado que el contexto previo elimina casi por completo la incertidumbre sobre la aparición de la "u", la cantidad de información nueva o "sorpresa" que genera la lectura de esta segunda letra pasa a ser prácticamente 0 bits.

En términos de modelado de fuentes con memoria (procesos de Markov), conocer el estado o símbolo anterior reduce la incertidumbre global, provocando que la entropía del sistema condicionado $H(S_M)$ sea estrictamente menor que la entropía de memoria nula $H(S_M) \leq H(S)$. Esto incrementa la redundancia del lenguaje y permite comprimir el texto con mayor eficiencia.

7. Para un sistema que debe poder representar $V = 1000000$ de estados diferentes:

- a) Para "bits" ($b = 2$):

$$\log_2(1000000) \cong 20 \text{ bits}$$

$$C1 = I \cdot b = 20 \cdot 2 = 40$$

Para "trits" ($b = 3$):

$$\log_3(1000000) \cong 13 \text{ bits}$$

$$C2 = I \cdot b = 13 \cdot 3 = 39$$

Como $C2 < C1$, la arquitectura de "trits" es más económica.

- b) Como $I = \log_b(V)$, entonces $C = I \cdot b = \log_b(V) \cdot b$

Por propiedad de logaritmo: $\log_b(V) = \frac{\ln(V)}{\ln(b)}$

$$C = \frac{\ln(V)}{\ln(b)} \cdot b = \ln(V) \cdot \frac{b}{\ln(b)}$$

derivamos e igualamos a 0:

$$\frac{dC}{db} = \ln(V) \cdot \frac{1 \cdot \ln(b) - b \cdot 1/b}{(\ln(b))^2} = 0$$

$$\frac{dC}{db} = \ln(V) \cdot \frac{\ln(b) - 1}{(\ln(b))^2} = 0$$

Para que sea igual a cero alguno de los siguientes términos tiene que ser igual a 0:

- $\ln(V)$ no puede ser, pues es un logaritmo.
- $(\ln(b))^2$ no puede ser, pues es un logaritmo.
- $\ln(b) - 1$ tiene que ser igual a 0:

$$\ln(b) - 1 = 0 \Rightarrow \ln(b) = 1$$

Por definición de logaritmo: $\ln(b) = 1 \Rightarrow e^1 = b \Rightarrow b = e$

Por lo tanto, la base teórica que minimiza la función de costo C para cualquier valor de V es euler (e).

- c) Debido a que no podemos tener bases fraccionarias, entonces el número más cercano a e es 3, y por lo tanto es la base teórica óptima.

8. Árboles de Decisión y Capacidad de Información Se tienen 12 monedas de apariencia idéntica, pero se sabe que exactamente una de ellas es falsa y tiene un peso diferente al resto (no se sabe a priori si es más pesada o más liviana). Usted dispone de una balanza de platillos clásica.

a) Sabiendo que cada pesada en la balanza (equilibrio, se inclina a la izquierda, se inclina a la derecha) genera una cierta cantidad de información, demuestre matemáticamente por qué son necesarias exactamente 3 pesadas para encontrar la moneda falsa y determinar su anomalía de peso.

b) Esquematice la metodología (el árbol de decisiones) de la primera pesada y de todas sus ramas para demostrar cómo se divide el espacio de incertidumbre respetando la base ternaria calculada.

a) Demostración Matemática del Número de Pesadas

1. Espacio de Estados e Incertidumbre Inicial (H_0)

Se tienen 12 monedas idénticas a la vista, donde exactamente una de ellas es falsa y tiene un peso diferente, pudiendo ser más pesada (+) o más liviana (-).

Para resolver el problema se requiere identificar cuál es la moneda falsa y determinar su anomalía de peso. Por lo tanto, el número de hipótesis o estados posibles equiprobables es:

$$\Omega = 12 \text{ monedas} \times 2 \text{ estados (+ o -)} = 24 \text{ estados equiprobables}$$

La entropía o incertidumbre inicial del sistema en unidades binarias (bits) es:

$$H_0 = \log_2 (24) = \log_2 (8 \times 3) = 3 + \log_2 (3) \approx 4,585 \text{ bits}$$

Expresada en base ternaria (trits):

$$H_0, \text{ternaria} = \log_3 (24) = \log_2 (24) / \log_2 (3) \approx 2,893 \text{ trits}$$

2. Capacidad de Información de la Balanza de Platillos ($I_{\square_{ax}}$)

Una balanza de platillos clásica realiza una medición con $r = 3$ resultados posibles y mutuamente excluyentes:

1. Inclinación a la izquierda (<): El platillo izquierdo es más pesado.
2. Equilibrio (=): Ambos platillos pesan lo mismo.
3. Inclinación a la derecha (>): El platillo derecho es más pesado.

La cantidad máxima de información que puede generar una pesada (al lograr equiprobabilidad entre las 3 salidas) es:

$$I_{\max} = \log_2 (3) \approx 1,585 \text{ bits/pesada}$$

(o 1 trit/pesada)

3. Cota Inferior y Cantidad Mínima de Pesadas (N)

De acuerdo con la cota de la Teoría de la Información para árboles de decisión ternarios, el número mínimo de pesadas N satisface:

$$N \geq H_0 / I_{\max} = \log_2 (24) / \log_2 (3) = \log_3 (24) \approx 2,893$$

Al ser las pesadas operaciones discretas, se aplica la función techo entero:

$$N = \lceil 2,893 \rceil = 3 \text{ pesadas}$$

Verificación combinatoria:

Con 2 pesadas:

$$3^2 = 9 < 24 \text{ estados} \rightarrow \text{insuficiente.}$$

Con 3 pesadas:

$$3^3 = 27 \geq 24 \text{ estados} \rightarrow \text{suficiente para cubrir las 24 hipótesis, dejando } 27 - 24 = 3 \text{ ramas sobrantes sin usar.}$$

b) Árbol de Decisiones (División del Espacio Ternario)

Nomenclatura:


- Monedas numeradas del 1 al 12.
- G: Moneda confirmada como genuina (de peso normal).
- i+: La moneda i es más pesada.
- i-: La moneda i es más liviana.

Primera Pesada (N = 1)

Para maximizar la entropía del test y dividir los 24 estados en 3 grupos iguales de 8 estados ($24 / 3 = 8$), se pesan 4 monedas contra 4 monedas:

Pesada 1: {1, 2, 3, 4} vs {5, 6, 7, 8}

(Quedan fuera de la balanza: {9, 10, 11, 12})



DESARROLLO DE LAS RAMAS DEL ÁRBOL

RAMA 1: EQUILIBRIO (=) — Probabilidad 1/3

- Monedas {1..8} son genuinas (G).
- La falsa está en {9, 10, 11, 12} (8 estados).

Pesada 2: {9, 10, 11} vs {G1, G2, G3}

1.1. EQUILIBRIO (=):

La falsa es la 12 (quedan 12+ y 12-).

Pesada 3: 12 vs G1

- Si $12 > G1 \rightarrow 12+$
- Si $12 < G1 \rightarrow 12-$

1.2. IZQUIERDA CAE ($9, 10, 11 > G$):

La falsa es pesada y está en $\{9, 10, 11\}$.

Estados: $\{9+, 10+, 11+\}$

Pesada 3: 9 vs 10

- Si $9 > 10 \rightarrow 9+$
- Si $9 < 10 \rightarrow 10+$
- Si $9 = 10 \rightarrow 11+$

1.3. DERECHA CAE ($9, 10, 11 < G$):

La falsa es liviana y está en $\{9, 10, 11\}$.

Estados: $\{9-, 10-, 11-\}$

Pesada 3: 9 vs 10

- Si $9 < 10 \rightarrow 9-$
- Si $9 > 10 \rightarrow 10-$
- Si $9 = 10 \rightarrow 11-$

RAMA 2: IZQUIERDA CAE ($\{1,2,3,4\} > \{5,6,7,8\}$) — Probabilidad $1/3$

- La falsa es pesada en la izquierda ($\{1+, 2+, 3+, 4+\}$)

O liviana en la derecha ($\{5-, 6-, 7-, 8-\}$).

- Monedas $\{9..12\} = G$.

Pesada 2: $\{1, 2, 5\}$ vs $\{3, 6, G1\}$

2.1. EQUILIBRIO ($=$):

La falsa está entre las no pesadas:

$\{4+, 7-, 8-\}$

Pesada 3: 7 vs 8

- Si $7 < 8 \rightarrow 7-$
- Si $7 > 8 \rightarrow 8-$
- Si $7 = 8 \rightarrow 4+$

2.2. IZQUIERDA CAE ($\{1,2,5\} > \{3,6,G1\}$):

Mantiene la inclinación original.

Estados: $\{1+, 2+, 6-\}$

Pesada 3: 1 vs 2

- Si $1 > 2 \rightarrow 1+$
- Si $1 < 2 \rightarrow 2+$
- Si $1 = 2 \rightarrow 6-$

2.3. DERECHA CAE ($\{1,2,5\} < \{3,6,G1\}$):

Se invirtió la inclinación.

Estados: $\{3+, 5-\}$

Pesada 3: 3 vs G1

- Si $3 > G1 \rightarrow 3+$
- Si $3 = G1 \rightarrow 5-$

RAMA 3: DERECHA CAE ($\{1,2,3,4\} < \{5,6,7,8\}$) — Probabilidad $1/3$

- La falsa es liviana en la izquierda ($\{1-, 2-, 3-, 4-\}$)
O pesada en la derecha ($\{5+, 6+, 7+, 8+\}$).
- Monedas $\{9..12\} = G$.

Pesada 2: $\{1, 2, 5\}$ vs $\{3, 6, G1\}$

3.1. EQUILIBRIO (=):

La falsa está entre:

$\{4-, 7+, 8+\}$

Pesada 3: 7 vs 8

- Si $7 > 8 \rightarrow 7+$
- Si $7 < 8 \rightarrow 8+$
- Si $7 = 8 \rightarrow 4-$

3.2. IZQUIERDA CAE ($\{1,2,5\} > \{3,6,G1\}$):

Se invirtió la inclinación respecto a la Pesada 1.

Estados: $\{3-, 5+\}$

Pesada 3: 3 vs G1

- Si $3 < G1 \rightarrow 3-$
- Si $3 = G1 \rightarrow 5+$

3.3. DERECHA CAE ($\{1,2,5\} < \{3,6,G1\}$):

Conserva la inclinación original.

Estados: $\{1-, 2-, 6+\}$

Pesada 3: 1 vs 2

- Si $1 < 2 \rightarrow 1-$
- Si $1 > 2 \rightarrow 2-$
- Si $1 = 2 \rightarrow 6+$

9. Información y Reducción de Incertidumbre En un programa de preguntas, el candidato debe encontrar un premio oculto detrás de una de tres puertas. El premio está detrás de cada puerta con igual probabilidad; una cabra está detrás de las otras dos puertas. Primero, el candidato elige una puerta.

a) ¿Cuál es la probabilidad de que el premio esté detrás de la puerta elegida?

b) El presentador del juego sabe detrás de qué puerta está oculto el premio. En lugar de abrir la puerta elegida, abre una de las otras dos puertas que contiene una cabra. Ahora, ofrece al candidato cambiar a la única puerta cerrada que queda. ¿Cuál es la probabilidad de ganar el premio cambiando de puerta?

c) **Análisis de la Información:** En términos de la Teoría de la Información, el estado inicial del juego posee una incertidumbre máxima. Cuando el presentador abre una puerta con una cabra, está transmitiendo un "mensaje" al candidato. Calcule la Entropía inicial del sistema y explique conceptualmente por qué la acción del presentador inyecta Información al sistema, rompiendo la equiprobabilidad.

a) Probabilidad de la puerta elegida inicialmente

Al comienzo del juego hay 3 puertas y el premio está distribuido de forma equiprobable:

$$p_1 = p_2 = p_3 = 1/3$$

- La probabilidad de que el premio esté detrás de la puerta elegida inicialmente es:
 $P(\text{Elegida}) = 1/3 \approx 33,33\%$

- La probabilidad complementaria de que el premio se encuentre en alguna de las otras dos puertas (el conjunto no elegido) es:
 $P(\text{No elegidas}) = 1 - 1/3 = 2/3 \approx 66,67\%$

b) Probabilidad de ganar al cambiar de puerta

La probabilidad de ganar el premio al aceptar el cambio de puerta es:

$$P(\text{Ganar cambiando}) = 2/3 = 66,67\%$$

Explicación del comportamiento del sistema:

1. Conocimiento a priori del presentador:

El presentador sabe dónde está el premio y sigue la regla estricta de nunca abrir la puerta elegida por el participante ni la puerta que contiene el premio.

2. Caso 1 (Elección inicial correcta, prob. 1/3):

Si el concursante eligió la puerta con el premio, las otras dos puertas tienen cabras. El presentador abre cualquiera de ellas. Si el concursante cambia de puerta, pierde.

3. Caso 2 (Elección inicial incorrecta, prob. 2/3):

Si el concursante eligió una puerta con cabra, el premio está en la otra puerta no elegida. El presentador no tiene opción: está obligado a abrir la única puerta no elegida que contiene la otra cabra. La puerta restante cerrada contiene el premio con certeza. Si el concursante cambia, gana.

Dado que la probabilidad de haber fallado en la primera elección era de 2/3, cambiar de puerta invierte los resultados y garantiza una probabilidad de éxito del 66,67%.

c) Análisis de la Información y Reducción de Incertidumbre

1. Entropía Inicial del Sistema (H_0)

Antes de cualquier acción, el sistema consta de $N = 3$ estados equiprobables, por lo que posee incertidumbre máxima:

$$H_0 = H_{\max} = -\sum_{i=1}^3 p_i \log_2(p_i) = \log_2(3) \approx 1,585 \text{ bits}$$

2. Inyección de Información y Ruptura de Equiprobabilidad

- El presentador como canal condicionado:

La acción del presentador no es un evento aleatorio (no tira un dado ni abre una puerta al azar); está totalmente condicionada por la ubicación real del premio y la puerta seleccionada.

- Transferencia de probabilidad asimétrica:

Al abrir una puerta con una cabra, el presentador aporta información que reduce la probabilidad de esa puerta específica a 0.

- Colapso sobre la puerta restante:

Como el presentador tenía prohibido abrir la puerta seleccionada por el jugador, la probabilidad de la puerta elegida permanece inalterada en 1/3. Por lo tanto, la masa de probabilidad del grupo no elegido (2/3) se concentra sobre la única puerta no elegida que permanece cerrada, rompiendo la equiprobabilidad original.

3. Cálculo de la Entropía a Posteriori y Reducción de Incertidumbre

Con la nueva distribución de probabilidades:

$$P = (1/3, 2/3, 0)$$

La entropía a posteriori del sistema es:

$$H_{\square\square\square} = -(1/3 \cdot \log_2 (1/3) + 2/3 \cdot \log_2 (2/3)) \approx 0,918 \text{ bits}$$

La cantidad de información inyectada por el mensaje del presentador (reducción neta de incertidumbre) es:

$$\Delta H = I = H_0 - H_{\square\square\square}$$

$$\Delta H = 1,585 - 0,918 = 0,667 \text{ bits}$$

El mensaje del presentador inyecta 0,667 bits de información, reduciendo la entropía del juego de 1,585 bits a 0,918 bits y demostrando cuantitativamente por qué cambiar de puerta es la decisión óptima.